Kinvecta

SERIE PARA FACILITADORES · SESIÓN 4 DE 8

Tokens, contexto y cómo encuentra la IA tus datos

El modelo solo ve lo que le mandas y lo que le regresan los buscadores.



Video de 8 minutos

Etapas 1–2

Guía 2.2 · 2.3

Kinvecta

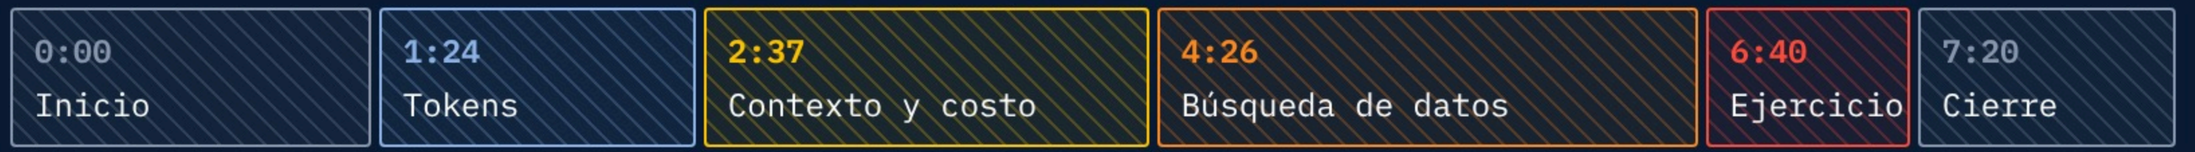
HOY

Al terminar, las personas participantes podrán…

1. Explicar qué es un token y por qué importa
2. Leer qué llena una ventana de contexto
3. Estimar el costo en tokens de un flujo de trabajo
4. Elegir el buscador correcto para tus datos

CAPÍTULOS · 8 MIN

a escala



Kinvecta

POR QUÉ IMPORTA

Tres quejas, una causa: lo que el modelo puede ver

01

“La factura nos sorprendió”

El costo viene del contexto que se reenvía en ciclos y chats largos, no de la respuesta.

02

“Se le olvidó lo que dije”

Los chats largos llenan la ventana; los primeros turnos se descartan o pierden atención.

03

“No encontró la tabla”

Se usó el buscador equivocado: al partir el texto, la tabla se volvió prosa.

La pregunta de esta sesión:

¿Qué ve el modelo y cuánto cuesta?

Kinvecta

TOKENS

Un token es el pedazo de texto que el modelo lee y escribe

Unos ¾ de palabra
Más o menos cuatro caracteres de texto en inglés

Códigos y cifras cuestan más
Código, tablas, IDs y otros idiomas se parten en más tokens

Cada proveedor cuenta distinto
Cada modelo tiene su tokenizador, así que los conteos son estimaciones



Kinvecta

TIPOS DE TOKENS

No todos los tokens son iguales ni cuestan lo mismo

ENTRADA

Tokens de entrada

Todo lo que se manda: instrucciones, herramientas, documentos, historial, pregunta

SALIDA

Tokens de salida

La respuesta; cuesta varias veces más y es lo que más hace esperar

RAZONAMIENTO

Tokens de razonamiento

El trabajo del modelo antes de responder; se cobra como salida

CACHÉ

Tokens en caché

Un prefijo estable que guarda el proveedor y se relee con descuento

IMAGEN · AUDIO

Imagen y audio

Páginas, imágenes y grabaciones convertidas en tokens

HERRAMIENTA

Tokens de herramientas

Cada herramienta conectada agrega su descripción a cada solicitud

EMBEDDING

Tokens de embedding

Se cobran cuando se indexan documentos para buscarlos

Regla

Lo que mandas cuesta más que lo que recibes

Kinvecta

LA VENTANA DE CONTEXTO

Una solicitud, un presupuesto fijo para entrada y salida

Todo compite
Instrucciones, herramientas, historial, documentos y respuesta: una sola ventana

Guarda en caché lo que no cambia
Un prefijo que se repite se guarda y se relee barato

Domina la entrada
Lo que mandas cuesta más que lo que recibes



Kinvecta

TOKENS EN UN CHAT

Cada turno reenvía toda la conversación

La API no guarda estado

Cada turno vuelve a mandar el prompt de sistema y todos los mensajes anteriores

Crece la entrada, no la salida

Los chats largos cuestan más en cada turno

El caché lo suaviza

El historial repetido se vuelve lecturas baratas



Kinvecta

POR QUÉ IMPORTAN LOS TOKENS

Seis razones por las que los tokens aparecen en tu trabajo

01

Costo

Tokens por ejecución × ejecuciones al mes

02

Capacidad

Una ventana para todo lo que mandas

03

Velocidad

Los tokens de salida se escriben uno por uno

04

Límite de uso

Los tokens por minuto tienen tope; los procesos por lotes se frenan

05

Calidad

Un contexto ligero y ordenado le gana a una ventana saturada

06

Cambiar de modelo

Conteos, costos y límites cambian con el tokenizador

Kinvecta

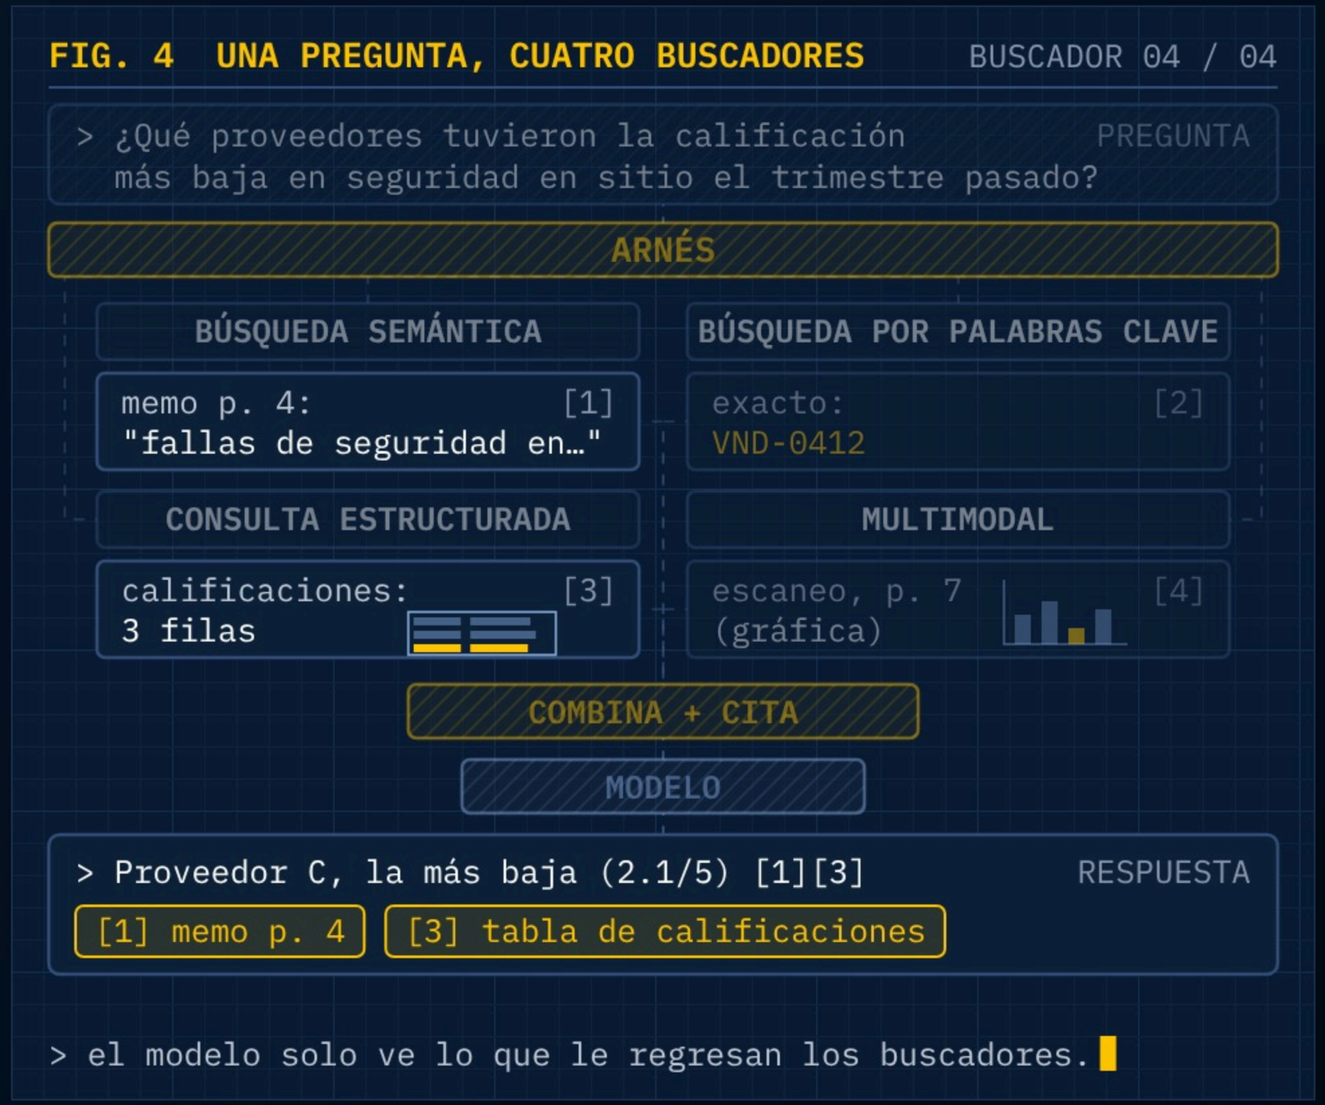
CÓMO ENCUENTRA LA IA TUS DATOS

El modelo solo ve lo que le dan los buscadores

Buscadores, no el modelo
El arnés hace las búsquedas; el modelo lee los resultados

Varios a la vez
Cada tipo de datos necesita su propio buscador

Combinados y citados
Los resultados se juntan y se entregan con citas



Kinvecta

SEIS FORMAS EN QUE LA IA OBTIENE DATOS

Ningún buscador cubre todos los tipos de datos

01

Todo en el contexto

Conjuntos pequeños y estables; el costo crece con cada pregunta

02

Búsqueda semántica

Encuentra por significado en mucha prosa; falla con IDs exactos y tablas

03

Búsqueda por palabras clave

Nombres, IDs y códigos exactos; falla con sinónimos

04

Búsqueda agéntica

Planea sus propias búsquedas en archivos vivos; cara en conjuntos enormes

05

Consultas estructuradas

Registros exactos de tablas y bases de datos; requiere una conexión aprobada

06

Multimodal

Escaneos, diapositivas y gráficas con su diseño; la más nueva y más cara

SEGURIDAD Un índice es una copia de tus datos. Necesita las mismas reglas de acceso y aprobaciones que la fuente.

Kinvecta

ELIGE EL BUSCADOR SEGÚN LOS DATOS

Cada tipo de datos tiene un buscador que le queda

TIPO DE DATOS	BUSCADORES QUE SIRVEN	QUÉ VIGILAR
Documentos de texto y memos	Búsqueda semántica + por palabras clave	Cita la página, no solo el archivo
Tablas y hojas de cálculo	Consultas estructuradas	Los totales salen de una consulta, no de que el modelo lea filas
Imágenes, escaneos, diapositivas	Recuperación multimodal o un modelo de visión	Revisa las cifras leídas de gráficas y escaneos
Código y configuración	Búsqueda agéntica	Los índices se desactualizan; lee los archivos vivos
Registros vivos	Solo consultas estructuradas, por una conexión aprobada	Control de acceso en la consulta; registra cada búsqueda

Kinvecta

LA REGLA DE ORO

Manda menos.
Guarda en caché lo que no cambia.
Usa el buscador correcto.

El modelo solo ve lo que le mandas y lo que le regresan los buscadores.

Kinvecta

EJERCICIO

Cuéntalo y luego encuéntralo

Pausa y practica

A Cuéntalo

1. Pega un prompt no sensible en un contador de tokens aprobado.
2. Anota los tokens de entrada y los de salida esperados.
3. Tokens por ejecución × ejecuciones al mes.
4. ¿Cuánto ahorraría un prompt más corto o el caché?

B Encuéntralo · ¿qué buscador?

1 ¿Cuál es nuestra política de trabajo remoto?

2 Encuentra el ticket INC-20418

3 Gasto total por proveedor este año

4 ¿Qué muestra la diapositiva del organigrama?

5 ¿Dónde está la lógica de reintentos en nuestro código?

6 Resume este informe de 3 páginas

Kinvecta

PON A PRUEBA LO APRENDIDO

¿Cada participante puede responder esto?

1

¿Más o menos cuánto texto es un token?

2

¿Por qué los chats largos cuestan más en cada turno?

3

¿Qué comparte la ventana de contexto?

4

¿Qué abarata el caché?

5

Menciona tres formas en que la IA obtiene datos.

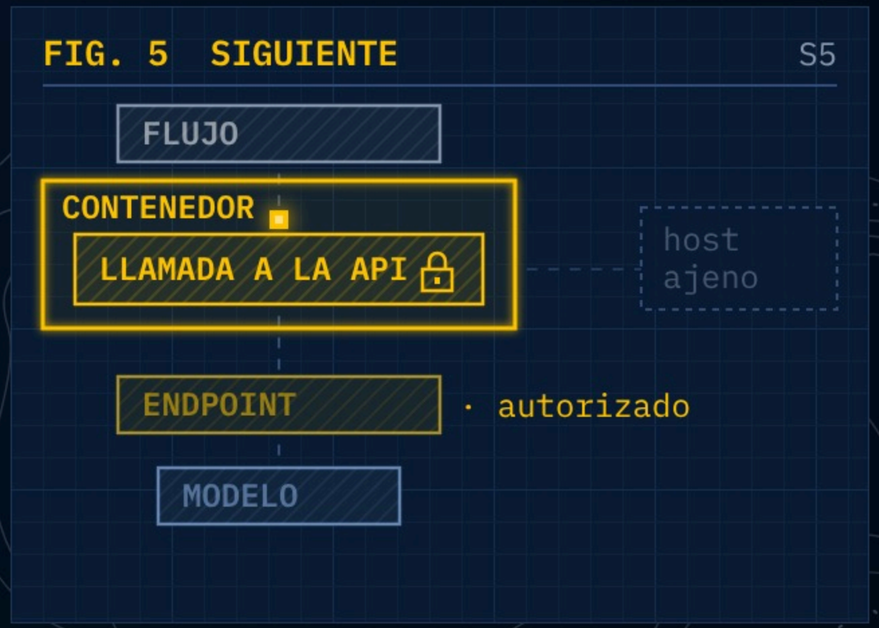
6

¿Por qué un índice de búsqueda es un tema de seguridad?

Kinvecta

SIGUIENTE · SESIÓN 5 · APIS, ENDPOINTS Y CONTENEDORES

¿Cómo llega tu propio software al modelo de forma segura?



Lo que cubre la Sesión 5

- Llamadas a la API
- Endpoints y configuración
- Contenedores
- Secretos y logs